

Detección de Comunidades en Redes mediante Simulated Annealing

Juan Miguel Guerrero Chíncoa y Adriana Navarrete Campillo
Universidad de Granada
6 de junio de 2026

El estudio de los sistemas complejos exige comprender la manera en que se conectan sus partes, ya que la estructura del mismo determina su comportamiento. Sin embargo, la escala y la topología de estos sistemas en ocasiones dificultan la extracción directa de dicha información. Aquí proponemos un enfoque estocástico basado en *simulated annealing* para representar la organización modular de redes complejas sin definir a priori el número de grupos. Específicamente, demostramos que el método (i) exhibe una alta robustez en escenarios donde es complicado divisar comunidades y (ii) supera el límite de resolución clásico mediante la modularidad generalizada, validando su precisión en el club de karate de Zachary y el conectoma humano. El algoritmo proporciona así un marco preciso y versátil para desvelar el orden funcional en redes complejas.

I. INTRODUCCIÓN

Cuando se presta atención a la estructura de muchos sistemas complejos, es común encontrarse con un patrón específico. En las relaciones sociales entre individuos, existen más probabilidades de estrechar vínculos con personas que piensan o se comportan de forma similar. Un estudio nacional sobre la salud en la adolescencia [1] mostró una clara división social en las relaciones de amistad en un instituto de Estados Unidos, marcada fuertemente por la raza (véase FIG. 1). Esta tendencia a agruparse con lo similar ha sido observada por sociólogos durante mucho tiempo y se conoce como *homofilia*. No es para nada un fenómeno autóctono de las relaciones sociales [2]. Se observa en Internet [3], en redes tróficas [4], en la organización de citas académicas [1] y en redes bioquímicas [5]. Por nombrar un ejemplo, Guimerà et al. [6] realizaron una cartografía compleja de redes metabólicas en varios organismos, identificando separaciones modulares de me-




FIG. 1: Red de relaciones de amistad en un instituto de educación secundaria en Estados Unidos. Los nodos blancos representan a estudiantes de raza blanca, los negros a estudiantes de raza negra y los grises a alumnos de otras etnias. Fuente: [1].

tabolitos relacionados por las funciones que desempeñan.

Parece entonces existir una especie de principio aglutinador que aúna a aquellos componentes de un sistema complejo con propósitos similares, instaurando una separación funcional en módulos. Puesto que en el azar no tienen cabida este tipo de estructuras organizadas, dichos componentes deben exhibir razones para interactuar más con ciertas partes del sistema y menos con otras. Con estos ejemplos, se hace evidente que la búsqueda de la estructura en comunidades en un sistema ofrece información muy valiosa para desvelar el orden dentro de la complejidad.

Una forma muy conveniente de representar dichos sistemas viene dada por la *teoría de redes*. En esencia, una red constituye una estructura topológica donde los nodos representan los componentes del sistema y los enlaces definen la existencia, o ausencia, de interacción entre ellos. En relaciones sociales, por ejemplo, nodos conectados podrían representar una afinidad entre personas. Además, podemos añadirle una etiqueta numérica (o un color) a cada nodo para clasificarlos en subgrupos. Dada una red “en crudo”, encontrar la división en subgrupos subyacente es lo que se conoce como *detección de comunidades*.

En este artículo, abordamos el reto de hallar estas fronteras naturales mediante técnicas de optimización global, conectando la detección de comunidades con la mecánica estadística.

II. FUNDAMENTO TEÓRICO

A. Teoría de redes

Para traducir los conceptos cualitativos de “estructura en comunidades” o “módulos” a un marco analítico riguroso y ejecutable mediante algoritmos de optimización, es indispensable dotar a las redes complejas de un lenguaje formal. El marco matemático idóneo para este objetivo es la teoría de grafos.

Bajo este enfoque, un grafo se define como un conjunto de elementos, los nodos del grafo, y un conjunto de líneas, o enlaces, que unen nodos entre sí. Más formalmente, un

grafo de N nodos y K enlaces consiste en dos conjuntos, $G \equiv (\mathcal{N}, \mathcal{L})$, con $\mathcal{N} = \{n_1, n_2, \dots, n_N\}$ el conjunto no vacío de nodos, y $\mathcal{L} = \{l_1, l_2, \dots, l_K\}$ los enlaces que unen pares de nodos. Puesto que los nodos representan elementos distintos del grafo, es conveniente asignarles un “nombre” o etiqueta, que suele ser un número entero desde 1 hasta N .

Una forma de representar los grafos se puede obtener usando una matriz, conocida como la *matriz de adyacencia*. La matriz de adyacencia de un grafo (simple) es una matriz cuadrada de tamaño $N \times N$ cuyo elemento a_{ij} vale 1 si los nodos i y j están conectados, y 0 en el caso contrario. En este proyecto, se limita el análisis a los grafos no dirigidos, aquellos en los que las líneas que unen los nodos no tienen una dirección predeterminada. De esta forma, $a_{ij} = a_{ji}$ por lo que la matriz de adyacencia es simétrica. Como convención, no se permiten autoconexiones, $a_{ii} = 0 \ \forall i = 1, \dots, N$.

La manera de etiquetar los nodos es arbitraria, y cada secuencia conduce a una multitud de representaciones equivalentes de la matriz de adyacencia asociada. De todas ellas, existe una configuración especial tal que la matriz muestra claramente interacciones por bloques. Esta representación se tratará con detalle más adelante.

Una propiedad fundamental es el *grado* del nodo i , denotado como k_i , que se define como el número de enlaces que emergen de él. Partiendo de esta definición, su expresión matemática se puede escribir como [1, 7]

$$k_i = \sum_{j=1}^N a_{ij}.$$

Nombraremos a las *conexiones internas* como aquellas que ocurren entre nodos pertenecientes a la misma comunidad, y las *conexiones externas* como las que unen nodos de comunidades distintas. Dicho así, el objetivo de la detección de comunidades consiste en encontrar una partición del conjunto de nodos en subconjuntos (las comunidades) tales que exista una alta densidad de conexiones internas y pocas externas [8]. Es evidente que la definición es ambigua e interpretable, lo que origina una gran variedad de formas para caracterizar una buena partición [1].

Denotamos convenientemente a una partición en M comunidades con el vector $\mathbf{c} = (c_1, \dots, c_N)$, siendo $c_i \in \{1, \dots, M \leq N\}$ la comunidad del nodo i . En vista de la definición del problema, una propuesta *naïve* para evaluar la calidad de una partición podría ser aquella que maximiza la fracción del número de conexiones internas,

$$\frac{1}{2K} \sum_{i,j=1}^N a_{ij} \delta(c_i, c_j), \quad (1)$$

donde el factor $1/2$ evita el doble conteo de enlaces al ser la matriz de adyacencia simétrica, y $\delta(\cdot, \cdot)$ es la delta de Kronecker. Sin embargo, el máximo de esa cantidad se corresponde con la partición trivial con $M = 1$, es decir, todos los nodos son asignados a la misma comunidad, de

modo que $\delta(c_i, c_j) = 1$ y la medida anterior resulta ser 1. Una mejor propuesta por [1] muestra que una buena partición es aquella en la que hay más enlaces internos de los que cabría esperar si la red se construye de forma aleatoria. Si se fija un esquema de construcción tal que los enlaces son lanzados uniformemente preservando el grado k_i de cada nodo, conocido como *configuration model* [9], llegamos a la función modularidad,

$$Q(\mathbf{c}) = \frac{1}{2K} \sum_{i,j=1}^N \left(a_{ij} - \frac{k_i k_j}{2K} \right) \delta(c_i, c_j), \quad (2)$$

donde el término de la derecha se corresponde con la fracción esperada de enlaces internos.

Este modelo nulo permite establecer una hipótesis de referencia de la cual deseamos distanciarnos si buscamos particiones no triviales. Con ello, podemos cuantificar desviaciones de lo típico, régimen en el que no se manifiesta la riqueza estructural consecuente de una organización deliberada en el patrón de conexiones de la red.

Aunque la ecuación (2) es la expresión más frecuente para evaluar la modularidad, Fortunato y Barthélémy [10] demostraron que su maximización presenta una limitación teórica fundamental conocida como el *límite de resolución*. Este método no es capaz de detectar estructuras modulares en redes que poseen comunidades muy pequeñas. Más concretamente, falla cuando el número de comunidades es mayor que $\sqrt{2K}$, causando que la modularidad máxima no se corresponda con la partición correcta.

Para solucionar este problema, Arenas et al.[11] propusieron una expresión generalizada para la modularidad,

$$Q(\mathbf{c}; \gamma) = \frac{1}{2K} \sum_{i,j=1}^N \left(a_{ij} - \gamma \frac{k_i k_j}{2K} \right) \delta(c_i, c_j), \quad (3)$$

donde el parámetro γ determina el peso asignado al modelo nulo frente a las conexiones reales de la red. Cuando $\gamma = 1$, la ecuación (3) se reduce a la definición tradicional de Newman (2). Nótese que $\gamma = 0$ devuelve la propuesta *naïve* (ec. 1) que maximiza la modularidad en la partición trivial que incluye a todos los nodos en una comunidad. Luego establecer $\gamma < 1$ atenúa el término corrector relativo al modelo nulo, lo que favorece comunidades más grandes. Por el contrario, configurar $\gamma > 1$ amplifica la presencia del término aleatorio y los subconjuntos grandes tienden a estar fuertemente penalizados, lo que permite sondear comunidades más pequeñas [9].

Notablemente, Newman, en su artículo [9], establece un marco teórico que demuestra la equivalencia exacta entre la maximización de la modularidad generalizada y el método de máxima verosimilitud (*maximum likelihood*) aplicado al *modelo de bloques estocásticos* corregido por el grado. Esta conexión proporciona una base matemática formal para la función de modularidad, alejándose de los argumentos puramente heurísticos.

B. Maximización de la modularidad mediante *simulated annealing*.

Hemos visto que el problema de detección de comunidades no tiene una definición bien delimitada, lo que conduce inevitablemente a la proliferación de métodos heurísticos en la literatura; en la mayoría, Q no interviene directamente. Por ejemplo, el algoritmo de Girvan-Newman [12] —estándar en la literatura de redes— identifica y corta sucesivamente los enlaces que actúan como “puentes” para la mayoría de los caminos más cortos entre los nodos, fragmentando así la red para tratar de revelar sus módulos [7]. Sin embargo, puesto que hemos argumentado que la función modularidad es una buena medida de la calidad de una partición, planteamos en este trabajo un algoritmo basado en la maximización directa de Q .

Es importante hacer notar que la modularidad, vista como una función que recibe una partición $\mathbf{c}$, presenta un grado elevado de degeneración en su espacio imagen. Esto significa que, para valores similares de modularidad, existe un número desorbitado de particiones asociadas a esa ventana de valores. Tratamos entonces con una función altamente no convexa, con un paisaje de valles y picos subóptimos que hacen prohibitiva la búsqueda de la combinación óptima por fuerza bruta [7].

En física estadística, este es el clásico problema de muestreo de la distribución de Boltzmann. Dicha distribución contiene las frecuencias relativas de las configuraciones de un sistema en equilibrio termodinámico, el cual se encuentra en contacto con un baño térmico a una temperatura inversa dada por $\beta = 1/k_B T$. Cuando la temperatura disminuye, la ocurrencia de aquellos microestados con energías mínimas se ve sumamente favorecida en la evolución del sistema [13, 14]. No obstante, de manera análoga al problema de detección de comunidades, el paisaje energético suele ser lo suficientemente complejo como para imposibilitar el sondeo de aquellos estados de mínima energía.

Para superar este obstáculo, Metropolis et al. [15] introdujeron el método Montecarlo basado en cadenas de Markov (MCMC), concebido para muestrear eficientemente la distribución de Boltzmann a temperaturas finitas. En esencia, el algoritmo propone una configuración candidata mediante una perturbación local del estado actual y evalúa su aceptación a través de una probabilidad de transición definida por

$$p = \begin{cases} 1 & \text{si } \Delta E \leq 0 \\ e^{-\beta \Delta E} & \text{si } \Delta E > 0, \end{cases} \quad (4)$$

donde $\Delta E = E_{\text{nueva}} - E_{\text{actual}}$ representa el incremento energético entre el estado propuesto y el actual. Este criterio de aceptación garantiza la condición de balance detallado y, con ello, la convergencia asintótica del sistema hacia un estado de equilibrio estadístico.

La principal ventaja de este procedimiento radica en que la formulación de Metropolis es completamente independiente de las leyes microscópicas reales que gobiernan las

transiciones físicas del sistema. Esta abstracción permite extrapolar el algoritmo fuera del dominio de la termodinámica convencional y aplicarlo en un contexto mucho más general, como el de los problemas de optimización combinatoria [13].

Kirkpatrick et al. [16] aprovecharon esta analogía para resolver problemas combinatorios mediante la minimización de una *función coste* —que emula el papel de la energía en los sistemas físicos—, fundando así el método de *simulated annealing*. Este algoritmo implementa un esquema de enfriamiento controlado que comienza a una temperatura elevada, lo que permite al sistema explorar ampliamente el espacio de configuraciones. Conforme el sistema alcanza el equilibrio térmico a cada nivel, la temperatura se reduce de manera gradual. Este proceso estocástico permite mitigar el riesgo de quedar atrapado en mínimos subóptimos, guiando la convergencia del sistema hacia la configuración óptima global o estado fundamental.

Este marco de trabajo resulta idóneo para hallar una partición que maximice la modularidad Q . El procedimiento opera de forma análoga al muestreo de configuraciones en el modelo de Ising: un vector de estado $\mathbf{s}$ almacena el microestado de una red de variables binarias (espines), y se aceptan secuencialmente nuevos estados que generen un cambio macroscópico ΔE en la energía del sistema de acuerdo con la probabilidad p (4). Una vez alcanzado el equilibrio térmico a una temperatura dada, esta se reduce siguiendo un esquema preestablecido y se relaja el sistema nuevamente. Al aproximarse asintóticamente a temperaturas lo suficientemente bajas, la distribución de Boltzmann colapsa hacia los estados de mínima energía, garantizando así que las configuraciones resultantes se ubiquen en el mínimo global del paisaje energético.

De manera equivalente, en este esquema se sustituye el vector de espines binarios $\mathbf{s}$ por el vector de comunidades $\mathbf{c}$ detallado en la SEC. IIB, que representa la partición de la red. Dado que el objetivo consiste en maximizar la modularidad Q , la energía del sistema se reemplaza por la función coste $C = -Q$ [1, 17]. Mediante esta equivalencia, el proceso estocástico garantiza el muestreo de particiones $\mathbf{c}$ asociadas a los valores mínimos de la función coste, es decir, los máximos de la modularidad. El algoritmo implementado toma como punto de partida la propuesta de Medus et al. [18], aunque presenta contribuciones metodológicas y técnicas de optimización propias, encaminadas a maximizar la eficiencia computacional y refinar la exploración del espacio de fases.

Es importante destacar que el algoritmo propuesto no requiere fijar de antemano el número de comunidades M , sino que este emerge como un resultado del propio proceso de optimización. Como consecuencia, se trata de una variable dinámica durante la evolución del vector de particiones. A esto se suma el hecho de que múltiples representaciones del vector $\mathbf{c}$ pueden codificar una misma partición física. Estas condiciones imponen la necesidad de implementar controles rigurosos en cada iteración para garantizar que las transiciones de estado propuestas sean

válidas y consistentes. Los detalles metodológicos del algoritmo se encuentran disponibles en la SEC. V A del material suplementario.

III. RESULTADOS

A. Verificación del algoritmo: Planted Partition Model (PPM)

Aunque la estructura en comunidades es una característica ubicua, es muy poco probable conocer la partición correcta de una red del mundo real. Así pues, para probar la funcionalidad de nuestro algoritmo, necesitamos una forma controlada de generar redes con comunidades predefinidas con la cual validar los resultados. Un *benchmark* de redes sintéticas muy usado es el *planted partition model* (PPM) [6, 7, 19].

El modelo comienza particionando el conjunto de N nodos en M subconjuntos de tamaño $n = N/M$. Después, conecta nodos con probabilidad p_{in} si ambos pertenecen al mismo subconjunto, y p_{out} en caso contrario. Si p_{out} es mucho menor que p_{in} , se generan redes con clústeres bien diferenciados; con $p_{out} = p_{in}$ la estructura es inexistente al crear una red totalmente aleatoria (grafo de Erdős-Rényi).

Así definido, las probabilidades de conexión interna y externa constituyen dos parámetros libres. Puede construirse un *benchmark* simplificado que genere una familia de grafos variando un solo parámetro al fijar una condición que ligue a p_{in} y p_{out} . Para hacer más interpretable el conjunto generado, se considera el número promedio de conexiones de un nodo con otros de su comunidad, $k_{in} = (n - 1)p_{in}$; de igual modo, el número promedio de conexiones con nodos de otra comunidad es $k_{out} = n(M - 1)p_{out}$, y el grado promedio es por tanto $\langle k \rangle = k_{in} + k_{out}$. Como k_{in} y k_{out} son respectivamente funciones de p_{in} y p_{out} , podemos fijar el grado promedio a una constante $\langle k \rangle = k$ y así ligar las probabilidades [7]. En este lenguaje, la condición $p_{in} = p_{out}$ se alcanza cuando la fracción promedio de conexiones externas es

$$\frac{k_{out}}{k} = \frac{N - n}{N - 1}. \quad (5)$$

Esta reparametrización del PPM, conocida como *Girvan-Newman benchmark* [20], es la que usamos para validar el rendimiento de nuestro algoritmo, usando la expresión estándar de Q con $\gamma = 1$ (ec. 2). En primer lugar, y siguiendo el protocolo de Guimerà et al. [6], definimos una familia de redes con $N = 128$ nodos, divididos en $M = 4$ comunidades de $n = 32$ nodos, cada uno con un grado promedio $k = 16$. Seguidamente, el algoritmo procesa cada red “en crudo”, es decir, sin la información relativa a la etiqueta correcta de comunidad de cada nodo. El resultado se esquematiza en la FIG. 2. Los paneles (a-c) muestran ejemplos de redes que el algoritmo debe tratar, en orden creciente de dificultad de acuerdo con el ratio de enlaces externos: (a) una estructura clara con $k_{in} = 15$ y $k_{out} = 1$; (b) una estructura

más difusa, $k_{in} = 11$ y $k_{out} = 5$; (c) la estructura de comunidades deja de ser evidente mediante inspección visual cuando $k_{out} = k_{in} = 8$. Como apunte, la condición $k_{out} = k_{in} = k/2$ no implica la disolución completa de la estructura en comunidades, pues las $k/2$ conexiones externas deben distribuirse en $M - 1$ comunidades, frente a las $k/2$ conexiones internas [8]. En su lugar, según indica la ec. (5), la estructura en comunidades se pierde cuando $k_{out}/k = 0.78125 \equiv q_{lim}$.

Como resultado principal, el algoritmo entrega la partición óptima encontrada. Comparada con la partición original, puede obtenerse la fracción de nodos correctamente clasificados. En el panel (d), representamos esa misma fracción en función de la fracción de enlaces externos, en contraste con el rendimiento del algoritmo de Girvan-Newman (véase SEC. IIB). El intervalo de conexiones internas barrido es $k_{out}/k \in [0, q_{lim}]$, y cada punto ha sido obtenido promediando con 80 simulaciones. Se suministra en el material suplementario la TAB. I para visualizar con precisión los resultados.

Es notable el hecho de que nuestro algoritmo es capaz de clasificar correctamente el 87.15 % de los nodos incluso en el régimen ruidoso $k_{out}/k = 0.5$, frente al 37.59 % del algoritmo de Girvan-Newman. Después de ese valor, el rendimiento de *simulated annealing* cae rápidamente al tratar con grafos cada vez más similares a un Erdős-Rényi. Cuando la fracción alcanza el límite q_{lim} , el algoritmo opera sobre ruido puro, por lo que se espera que, en promedio, clasifique correctamente una fracción de $1/M = 0.25$ nodos. En efecto, el rendimiento se estabiliza en dicho valor.

Adicionalmente, el algoritmo devuelve la matriz de adyacencia reordenada con una enumeración de nodos tal que revela los bloques de interacciones intracomunitarias. En (e), se aprecia la matriz resultante tras recibir la red (b), con $k_{out}/k = 0.3$.

B. Club de karate de Zachary

Una vez verificado el buen rendimiento del algoritmo de maximización de modularidad por *simulated annealing* con redes sintéticas, nos movemos a redes del mundo real. Un ejemplo clásico en la literatura es la red del club de karate de Zachary, la cual demuestra cómo la detección de comunidades desvela información relevante sobre el comportamiento del sistema [7].

Wayne W. Zachary, antropólogo de formación, estudió durante tres años las relaciones interpersonales entre los miembros de un club universitario de karate. En su artículo [22], Zachary modeló formalmente una red social de interacciones basada en los vínculos entre los miembros del club, el instructor de karate (Mr. Hi) y el presidente del club (John A.). Al inicio del estudio, ya existía un conflicto latente entre los dos líderes respecto a la fijación de precios de las clases. Con el transcurso del tiempo, las dos opiniones polarizaron a los miembros del club en dos grupos claramente diferenciados.




FIG. 2: Validación mediante el *benchmark* de Girvan-Newman. Redes de $N = 128$, $M = 4$ comunidades y grado $k = 16$. (a-c) Ejemplos de dificultad creciente según el ratio de enlaces externos (k_{out}/k): desde una estructura evidente (a) hasta el límite de inspección visual (c), donde $k_{in} = k_{out} = 8$. (d) Fracción de nodos correctamente clasificados frente a k_{out}/k . Nuestro algoritmo mantiene una precisión del 87.15 % incluso en el régimen donde, en promedio, hay tantas conexiones internas como externas ($k_{out}/k = 0.5$). Cada punto ha sido obtenido promediando con 80 simulaciones. (e) Matriz de adyacencia de la red (b) reordenada según la partición óptima, donde se evidencian los bloques intracomunitarios. Resultado reproducido a partir de la FIG. 1 de Guimerà et al.[6].

En la FIG. 3(a) se ilustra la red mapeada por Zachary en pleno auge del conflicto. Los nodos representan a los integrantes del club, destacando los roles centrales del instructor y el presidente (representados mediante los nodos cuadrados 1 y 2, respectivamente). Esta visualización revela la emergencia de dos subgrupos: los nodos blancos denotan a los partidarios de Mr. Hi, mientras que los nodos grises corresponden a los afines a John A. En este contexto, es evidente la existencia de una fragmentación real de las amistades entre los miembros condicionada por la afinidad ideológica [7].

Como comentario, este escenario representa un caso excepcional donde la estructura comunitaria real ha sido documentada de antemano. Sin embargo, lo habitual en la práctica es no tener acceso a la partición de referencia (*ground truth*), lo que ha convertido a esta red en un ejemplo estándar en la literatura [7].

En la FIG. 3(b), se observa el resultado del algoritmo al maximizar la modularidad con $\gamma = 1$ (ec. 2). Con dicho valor del parámetro, la partición óptima se corresponde con 4 comunidades para $Q = 0.420$, en contraste con el

valor de la partición clásica, $Q = 0.358$. Sin embargo, al ajustar $\gamma = 0.5$, se ven favorecidas particiones óptimas que cuentan con un menor número de comunidades (véase SEC. II). En este caso, obtenemos la partición de la FIG. 3(c), que recupera la estructura binaria con solo dos nodos clasificados incorrectamente. Los valores de modularidad se aproximan más; el algoritmo arroja $Q = 0.622$, frente a la partición de Zachary, $Q = 0.609$.

Este ejemplo ilustra el hecho de que la partición verdadera puede no corresponderse en general con el máximo matemático de modularidad. Los resultados permiten observar que la verdad empírica reside a menudo en estados subóptimos cercanos al fundamental.

C. Estructuras jerárquicas: conectoma humano

El cerebro humano se entiende como un sistema complejo cuya estructura física determina su funcionamiento. Uno de los objetos de estudio en este campo consiste en entender los mecanismos de transmisión de información




FIG. 3: Red de interacciones sociales entre los miembros del club de karate de Zachary, compuesta por 34 nodos y dividida en dos comunidades. (a) Red documentada por Zachary. Los nodos cuadrados 1 y 2 representan al instructor y al presidente, respectivamente. (b) Red de zachary tras aplicarle *simulated annealing* con $\gamma = 1$. Se aprecia una división en 4 comunidades. (c) Red de zachary tras aplicar el algoritmo con $\gamma = 0.5$. La partición proporciona 2 comunidades, al igual que en la red original (a), con dos nodos incorrectamente clasificados.

y la interacción entre distintas regiones del cerebro, para lo cual se emplean técnicas avanzadas de imágenes por resonancia magnética (MRI). La “red de carreteras” por las que fluye la información entre *regiones de interés* (ROIs) determina en neurociencia lo que se denomina *conectividad estructural*.

Con el propósito de visualizar esta red de conexiones, el estudio de Škoch et al. [21] generó, a partir de una muestra de 88 individuos sanos de entre 18 y 48 años, un conjunto de matrices de conectividad estructural. Para su construcción, el cerebro se dividió en 90 ROIs siguiendo el atlas AAL [23]. Denotemos al conjunto $\{a_{ij}^{(n)}\}_{n=1}^{88}$, con $i, j = 1, \dots, 90$. A priori, cada matriz es un conjunto de 90×90 números enteros, donde cada entrada cuantifica la proporción de fibras que conectan la ROI- i con la ROI- j .

A continuación, se calcula la matriz promedio $\bar{a}_{ij}$ y se aplica un valor umbral de 0.01, siguiendo el criterio de [21]. Este procedimiento permite capturar las conexiones más significativas y limitar el ruido o datos espurios derivados de la tractografía. El resultado es una red cerebral donde los nodos son las ROIs y los enlaces son las conexiones físicas entre ellas. La obtención de este grafo permite trasladar el análisis neurocientífico al marco de la teoría de redes, posibilitando la aplicación de las técnicas de partición detalladas anteriormente.

En la FIG. 4 se agrupan los resultados obtenidos. El panel (a1) ilustra la partición óptima de la red en 4 comunidades tras aplicar *simulated annealing*, usando la función modularidad con $\gamma = 1$. A su derecha, en (a2), se presenta la matriz de conectividad estructural para las 90 ROIs. Los nodos han sido enumerados con el orden seguido en [21] para reproducir el mismo resultado del correspondiente artículo.

De acuerdo con dicho referente, la arquitectura del conectoma se organiza en una escala jerárquica compuesta por 8 macrorregiones funcionales: prefrontal, motora, insu-

la, parietal, temporal, occipital, límbica y subcortical. En vista de lo anterior, podemos ajustar el parámetro $\gamma > 1$ para favorecer aquellas particiones con un mayor número de comunidades y de menor tamaño. De este modo, se busca desplazar la escala de observación del algoritmo hacia niveles más finos de la jerarquía, con el objetivo de reproducir la clasificación en las 8 macrorregiones anatómicas mencionadas.

Es necesario subrayar que el algoritmo es estocástico, y por tanto diferentes ejecuciones pueden arrojar particiones distintas. En consecuencia, la selección del factor γ se fundamenta en la búsqueda de una robustez estadística suficiente en los resultados. El mejor valor hallado es $\gamma = 2.18$, obteniendo la división en 8 comunidades en el 96.5 % de los casos, tras 200 simulaciones independientes.

En el panel (b1) se observa la nueva clasificación resultante en 8 comunidades. En la SEC. VC del material suplementario proporcionamos la organización detallada de las 90 ROIs en estas comunidades, posiblemente hallando una separación realista en módulos funcionales. Finalmente, en (b2) se presenta la matriz reindexada atendiendo al resultado anterior; en ella se revela con claridad la organización en bloques y el consecuente descenso en la escala de resolución de la red.

Este resultado demuestra la capacidad del algoritmo para navegar por la estructura jerárquica del conectoma, permitiendo transicionar de una visión macroscópica a una organización modular más detallada mediante el ajuste de un único parámetro de control.

IV. CONCLUSIONES

En este trabajo se ha implementado y validado un algoritmo de optimización global basado en *simulated annealing* para la detección de comunidades en redes




FIG. 4: Ilustración de la red del conectoma humano junto con su matriz de adyacencia. (a1) Red del conectoma dividida en 4 comunidades tras aplicarle *simulated annealing* con $\gamma = 1$. (a2) Matriz de adyacencia correspondiente a la red (a1). (b1) Red del conectoma fragmentada en 8 comunidades tras aplicar el algoritmo con $\gamma = 2.18$. (b2) Matriz de adyacencia correspondiente a la red (b1) tras reordenar los nodos. Resultado reproducido a partir de la FIG. 2 del artículo de Škoch et al. [21]

complejas a través de la maximización directa de la modularidad. La verificación empírica mediante el benchmark de Girvan-Newman (*Planted Partition Model*) demuestra la capacidad del algoritmo para clasificar correctamente nodos en comunidades, manteniendo una precisión del 87.15% en la fracción correctamente clasificada de los nodos en regímenes con un grado externo del nodo elevado ($k_{out}/k = 0.5$), que supera considerablemente a la fracción clasificada por el algoritmo clásico de Girvan-Newman, 37.59%.

Por otra parte, la aplicación de *simulated annealing* a la red de Zachary muestra el importante papel que juega el parámetro γ en la expresión de la modularidad. Mientras que la modularidad tradicional ($\gamma = 1$) divide la red en 4 comunidades, la parametrización a $\gamma = 0.5$ permite recuperar la estructura binaria real del conflicto con solo dos nodos clasificados de forma incorrecta. Asimismo, el estudio del conectoma humano demuestra la utilidad de configurar factores $\gamma > 1$ ($\gamma = 2.18$) para explorar estructuras jerárquicas en subgrupos, logrando identificar 8 comunidades bien definidas en las 90 regiones analizadas del cerebro.

Estos resultados validan experimentalmente las tesis

de Newman [1] y permiten extraer tres reflexiones fundamentales sobre la naturaleza de las redes en el marco de la física de los sistemas complejos:

En primer lugar, no existen razones teóricas para asumir que el valor convencional $\gamma = 1$ sea intrínsecamente correcto. Como se ha demostrado, la modularidad máxima para $\gamma = 1$ no siempre coincide con la partición verdadera del sistema; la modularidad no es un valor absoluto, sino una función de respuesta que depende de la escala en la que busquemos el orden.

En segundo lugar, la capacidad de detectar estas estructuras es lo que nos permite distinguir la organización deliberada del azar. Mientras que en un sistema puramente aleatorio no tiene cabida la riqueza modular, la emergencia de comunidades en el cerebro o en las redes sociales es la huella de un propósito subyacente, ya sea funcional o biológico. La detección de comunidades actúa, por tanto, como un filtro que aísla las desviaciones significativas de lo típico para revelar la arquitectura interna del sistema.

Finalmente, debemos concluir que una red puede albergar simultáneamente comunidades con un amplio espectro de tamaños y jerarquías. Por ello, no existe un único va-

lor “óptimo” de γ , sino que este parámetro actúa como una lente de resolución. El éxito de este trabajo reside en demostrar que, mediante el uso de técnicas de optimización global como el *simulated annealing*, es posible

utilizar dicha lente para cartografiar la complejidad de un sistema, permitiendo al investigador decidir si desea observar el bosque o los árboles.

-
- [1] M. E. J. Newman, *Networks: An Introduction*, reprinted ed. (Oxford University Press).
 - [2] R. Guimerà, L. Danon, A. Díaz-Guilera, F. Giralt, and A. Arenas, Self-similar community structure in a network of human interactions, **68**, 065103.
 - [3] K. A. Eriksen, I. Simonsen, S. Maslov, and K. Sneppen, Modularity and Extreme Edges of the Internet, **90**, 148701.
 - [4] S. L. Pimm, The structure of food webs, **16**, 144.
 - [5] L. H. Hartwell, J. J. Hopfield, S. Leibler, and A. W. Murray, From molecular to modular cell biology, **402**, C47.
 - [6] R. Guimerà and L. A. Nunes Amaral, Functional cartography of complex metabolic networks, **433**, 895.
 - [7] V. Latora, V. Nicosia, and G. Russo, *Complex Networks: Principles, Methods and Applications*, 1st ed. (Cambridge University Press).
 - [8] L. Danon, A. Díaz-Guilera, J. Duch, and A. Arenas, Comparing community structure identification, **2005**, P09008.
 - [9] M. E. J. Newman, Equivalence between modularity optimization and maximum likelihood methods for community detection, **94**, 052315 ().
 - [10] S. Fortunato and M. Barthélemy, Resolution limit in community detection 10.48550/ARXIV.PHYSICS/0607100.
 - [11] A. Arenas, A. Fernandez, and S. Gomez, Analysis of the structure of complex networks at different resolution levels 10.48550/ARXIV.PHYSICS/0703218.
 - [12] M. Girvan and M. E. J. Newman, Community structure in social and biological networks, **99**, 7821.
 - [13] E. Bonomi and J.-L. Lutton, The N-City Travelling Salesman Problem: Statistical Mechanics and the Metropolis Algorithm, **26**, 551, 2030978.
 - [14] P. J. M. Van Laarhoven and E. H. L. Aarts, *Simulated Annealing: Theory and Applications* (Springer Netherlands).
 - [15] N. Metropolis, A. W. Rosenbluth, M. N. Rosenbluth, A. H. Teller, and E. Teller, Equation of State Calculations by Fast Computing Machines, **21**, 1087.
 - [16] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi, Optimization by Simulated Annealing, **220**, 671.
 - [17] R. Guimerà and L. A. N. Amaral, Cartography of complex networks: Modules and universal roles, **2005**, P02001.
 - [18] A. Medus, G. Acuña, and C. O. Dorso, Detection of community structures in networks via global optimization, **358**, 593.
 - [19] A. Condon and R. M. Karp, Algorithms for graph partitioning on the planted partition model, **18**, 116.
 - [20] M. E. J. Newman and M. Girvan, Finding and evaluating community structure in networks 10.48550/ARXIV.COND-MAT/0308217.
 - [21] A. Škoch, B. Reháč Bučková, J. Mareš, J. Tintěra, P. Sanda, L. Jajcay, J. Horáček, F. Španiel, and J. Hlinka, Human brain structural connectivity matrices—ready for modelling, **9**, 486.
 - [22] W. W. Zachary, An Information Flow Model for Conflict and Fission in Small Groups, **33**, 452.
 - [23] N. Tzourio-Mazoyer, B. Landeau, D. Papathanassiou, F. Crivello, O. Etard, N. Delcroix, B. Mazoyer, and M. Joliot, Automated Anatomical Labeling of Activations in SPM Using a Macroscopic Anatomical Parcellation of the MNI MRI Single-Subject Brain, **15**, 273.

V. MATERIAL SUPLEMENTARIO

A. Implementación del algoritmo de *simulated annealing*

Se reserva este apartado para realizar una breve exposición de la lógica del algoritmo de detección de comunidades mediante *simulated annealing* usado en este trabajo.

El estado del sistema se codifica mediante un vector de partición $\mathbf{c} \in \mathbb{N}^N$, donde $c_i \in \{0, 1, \dots, M-1\}$ indica la comunidad a la que pertenece el nodo i , y M es el número actual de comunidades. Este número no se fija a priori, sino que varía dinámicamente a lo largo de la optimización. Para evitar redundancias en la representación, el vector se mantiene en forma “canónica”: las etiquetas de comunidad se asignan en orden de primera aparición, de modo que $c_0 = 0$ siempre, y cada nueva etiqueta es el mínimo entero no utilizado. Se introduce además un índice $m_\emptyset$ que apunta a la primera etiqueta vacía disponible, permitiendo proponer la creación de una nueva comunidad en cada iteración. Para rastrear el tamaño de cada comunidad de forma eficiente, se mantiene un vector de ocurrencias $\boldsymbol{\sigma}$, donde σ_m es el número de nodos actualmente asignados a la comunidad m . De forma análoga, el vector $\mathbf{K}_{\text{inn}}$, con $K_{\text{inn},m} = \sum_{i \in C_m} k_i$, acumula la suma de grados de los nodos de cada comunidad. Este último término se define por ser necesario en la evaluación del cambio ΔQ de modularidad entre la partición actual y la propuesta, como se verá a continuación.

En cada iteración se selecciona aleatoriamente un nodo l de comunidad $m_i = c_l$, y se propone su transferencia a una comunidad destino $m_j \neq m_i$, elegida uniformemente entre las comunidades existentes o bien la comunidad vacía $m_\emptyset$.

Puesto que el algoritmo es computacionalmente costoso, es necesario llevar a cabo una exhaustiva implementación de técnicas optimizadas. Una de ellas involucra el cálculo del cambio de modularidad entre configuraciones, ΔQ . La ecuación (2) puede reescribirse convenientemente como

$$Q(\mathbf{c}; \gamma) = \sum_{m=1}^M \left[\frac{K_{mm}}{K} - \left(\frac{K_{\text{inn},m}}{2K} \right)^2 \right],$$

donde m indexa las etiquetas de comunidad, $K_{mm} = 1/2 \sum_{i,j \in C_m} a_{ij}$ es el número de conexiones entre nodos que pertenecen a la comunidad C_m y $K_m = \sum_{i \in C_m} k_i$ es la suma de los grados de todos los nodos que pertenecen a C_m . El cambio de modularidad asociado a la propuesta $c_l = m_i \rightarrow m_j$ se calcula usando la expresión anterior, y resulta en

$$\Delta Q = \frac{k_{l \rightarrow m_j} - k_{l \rightarrow m_i}}{K} - \gamma \frac{k_l (k_l + K_{\text{inn},m_j} - K_{\text{inn},m_i})}{2K^2},$$

donde $k_{l \rightarrow m}$ denota el número de aristas entre el nodo l y la comunidad m . El cálculo eficiente de $k_{l \rightarrow m_i}$ y $k_{l \rightarrow m_j}$ se realiza mediante una representación en formato *Compressed Sparse Row* (CSR) de la matriz de adyacencia, de

manera que los vecinos de cualquier nodo se recuperan rápidamente sin materializar la matriz densa. Como optimización adicional, las propuestas a comunidades con las que el nodo l no tiene ninguna arista ($k_{l \rightarrow m_j} = 0$) se descartan antes de evaluar ΔQ , pues un movimiento de este tipo rara vez puede incrementar la modularidad [18].

La propuesta se acepta con probabilidad

$$P(\Delta Q) = \min(1, e^{\beta \Delta Q}),$$

donde β juega el papel de temperatura inversa. Cuando la propuesta aceptada vacía una comunidad ($\sigma_{m_i} = 0$), el vector canónico se actualiza mediante una función **shift**, que renombra todas las etiquetas superiores a m_i decrementándolas en una unidad, y desplaza en consecuencia los vectores $\boldsymbol{\sigma}$ y $\mathbf{K}_{\text{inn}}$, manteniendo así la forma canónica de $\mathbf{c}$ sin coste de memoria adicional.

La temperatura inicial β_0 se estima automáticamente mediante un paseo aleatorio previo de T_{rnd} pasos en el que todas las propuestas se aceptan. Durante este paseo se registran todos los cambios de modularidad negativos $\Delta Q < 0$, y se calcula su valor medio $\langle \Delta Q \rangle_-$. La temperatura inicial se fija entonces exigiendo que los movimientos desfavorables típicos sean aceptados con probabilidad p_0 (e.g. $p_0 = 0.85$):

$$\beta_0 = \frac{\ln p_0}{\langle \Delta Q \rangle_-}.$$

La temperatura inversa se actualiza geométricamente tras cada barrido de N_T propuestas a temperatura fija:

$$\beta_{t+1} = \alpha \beta_t, \quad \alpha > 1.$$

El factor α puede especificarse directamente o derivarse de la condición de que, tras S pasos de enfriamiento, la probabilidad de aceptar un movimiento desfavorable típico sea p_S :

$$\alpha = \left(\frac{\ln p_S}{\beta_0 \langle \Delta Q \rangle_-} \right)^{1/S}.$$

El algoritmo se declara finalizado (*frozen*) cuando se acumulan N_{frz} rechazos consecutivos, lo que indica que el sistema ha quedado atrapado en un mínimo local a temperatura efectivamente nula. A lo largo de toda la evolución se registra la partición $\mathbf{c}_{\text{max}}$ correspondiente al máximo de modularidad observado Q_{max} , que constituye el resultado del algoritmo.

B. Datos para la realización de la FIG. 2(d)

En la TAB. I se encuentran tabulados los datos usados para realizar la gráfica de la figura 2, obtenidos tras realizar el promedio de 80 simulaciones.

C. Organización en comunidades de las regiones del conectoma humano

En esta sección se detalla la organización en comunidades de las distintas ROIs obtenidas a partir de las matrices de Škoch et al. [21] y el atlas AAL [23], recogida en la TAB. II. Si bien no se dispone de información de referencia con la que contrastar la validez de esta agrupación de las regiones del conectoma, el análisis visual en la FIG. 4 y el examen de la correspondencia anatómica del atlas AAL indican que los resultados obtenidos por el algoritmo podrían reflejar una separación funcional en módulos, como puede observarse en la siguiente tabla. El algoritmo tiende a asociar regiones situadas en el mismo hemisferio, esto se observa en todas las comunidades excepto en la 6, donde aparecen agrupadas regiones de ambos hemisferios, posiblemente porque están situadas cerca de la interfase.

Tabla I: Tabla con los datos de la FIG. 2.

k_{out}/k	Fracción SA	Fracción GN
0.00000	1.0000	0.9922
0.03125	1.0000	1.0000
0.06250	1.0000	1.0000
0.09375	1.0000	1.0000
0.12500	1.0000	1.0000
0.15625	1.0000	1.0000
0.18750	1.0000	0.9999
0.21875	0.9998	0.9988
0.25000	0.9996	0.9989
0.28125	0.9994	0.9919
0.31250	0.9985	0.9890
0.34375	0.9970	0.9593
0.37500	0.9929	0.8750
0.40625	0.9867	0.7800
0.43750	0.9749	0.6517
0.46875	0.9405	0.5027
0.50000	0.8715	0.3759
0.53125	0.6760	0.2784
0.56250	0.5370	0.2269
0.59375	0.4096	0.1991
0.62500	0.3559	0.1858
0.65625	0.3163	0.1677
0.68750	0.2957	0.1607
0.71875	0.2730	0.1562
0.75000	0.2626	0.1484
0.78125	0.2515	0.1548

Tabla II: ROIs asociadas a cada comunidad.

Comunidad Partes		ROIs
Comunidad 1	7	L Precentral Gyrus, L IFG (p. Opercularis), L Rolandic Operculum, L Insula Lobe, L Postcentral Gyrus, L SupraMarginal Gyrus, L Thalamus.
Comunidad 2	10	R Precentral Gyrus, R IFG (p. Opercularis), R Rolandic Operculum, R Insula Lobe, R Postcentral Gyrus, R Superior Parietal Lobule, R Inferior Parietal Lobule, R SupraMarginal Gyrus, R Angular Gyrus, R Heschls Gyrus.
Comunidad 3	14	L Superior Frontal Gyrus, L Superior Orbital Gyrus, L Middle Frontal Gyrus, L Middle Orbital Gyrus, L IFG (p. Triangularis), L IFG (p. Orbitalis), L Olfactory cortex, L Superior Medial Gyrus L Mid Orbital Gyrus, L Rectal Gyrus, L Cingulum Ant, L Caudate Nucleus, L Putamen, L Pallidum.
Comunidad 4	15	R Superior Frontal Gyrus, R Superior Orbital Gyrus, R Middle Frontal Gyrus, R Middle Orbital Gyrus, R IFG (p. Triangularis), R IFG (p. Orbitalis), R Olfactory cortex, R Superior Medial Gyrus, R Mid Orbital Gyrus, R Rectal Gyrus, R Cingulum Ant, R Caudate Nucleus, R Putamen, R Pallidum, R Thalamus.
Comunidad 5	6	L Posterior-Medial Frontal, R Posterior-Medial Frontal, L Cingulum Mid, R Cingulum Mid, L Paracentral Lobule, R Paracentral Lobule.
Comunidad 6	14	L Cingulum Post, L Calcarine Gyrus, L Cuneus, L Lingual Gyrus, L Superior Occipital Gyrus, L Middle Occipital Gyrus, L Inferior Occipital Gyrus, L Superior Parietal Lobule, L Inferior Parietal Lobule, L Angular Gyrus, L Precuneus, L Heschls Gyrus, L Superior Temporal Gyrus, L Middle Temporal Gyrus.
Comunidad 7	17	R Cingulum Post, R Hippocampus, R ParaHippocampal Gyrus, R Amygdala, R Calcarine Gyrus, R Cuneus, R Lingual Gyrus, R Superior Occipital Gyrus, R Middle Occipital Gyrus, R Inferior Occipital Gyrus, R Fusiform Gyrus, R Temporal Pole, R Middle Temporal Gyrus, R Medial Temporal Pole, R Inferior Temporal Gyrus, R Precuneus, R Superior Temporal Gyrus.
Comunidad 8	7	L Hippocampus, L ParaHippocampal Gyrus, L Amygdala, L Fusiform Gyrus, L Temporal Pole, L Medial Temporal Pole, L Inferior Temporal Gyrus.